


## Genlikte Sürekli Algılayıcı (ADALİNE)

Bernard Widrow-Tedd Hoff (1960)



$$v = [w_1 \ w_2 \ \dots \ w_n \ w_{n+1}] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} \quad v = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} 1$$


$$y = \varphi(v) = \tanh av$$


$$y = \varphi(v) = \frac{1}{1 + e^{-av}}$$

## Genlikte Sürekli Algılayıcı (ADALİNE)

Bernard Widrow-Tedd Hoff (1960)

$$y = \varphi(v) = \frac{1}{1 + e^{-av}}$$





Amaç: hatayı azaltacak ağırlıkları belirlemek  
Hataya ilişkin bir fonksiyon oluşturularak işe başlanacak

$$e = y_d - y$$

$$E = \frac{1}{2} e^T e = (y_d - y)^T (y_d - y) = (y_d - \phi(v))^T (y_d - \phi(v))$$

Nasıl azaltabiliriz?

Verilen eğitim kümesi için, hata fonksiyonu  $E$  'yi öğrenme performansının ölçütü olarak al ve bu amaç ölçütünü enazlayan parametreleri belirle.

### EK BİLGİ

#### Bazı Eniyileme (Optimizasyon) Teknikleri

##### Eniyileme problemi

$$\min_{x \in \Omega} f(x) \quad f(x): R^n \rightarrow R$$

Kısıtlar:  $h(x) = 0 \quad g(x) \leq 0$

$$h(x): R^n \rightarrow R^p \quad g(x): R^n \rightarrow R^m$$

##### Kısıtsız Eniyileme Problemi

$$\min_{x \in R^n} f(x)$$

**Teorem:**  $\Omega \in \mathbb{R}^n$ ,  $f(\cdot) \in C^1$

1. Mertebeden gerek koşul  $x^* \in \Omega$   $f(\cdot)$ 'in ekstremum noktası ise

$$\nabla f(x^*) = 0$$

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} \quad \nabla^2 f = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

$$f(x_1, x_2, x_3) = x_1^2 + x_1 x_3 + x_2^2 x_3$$

$$\nabla f = \begin{bmatrix} 2x_1 + x_3 \\ 2x_2 x_3 \\ x_1 + x_2^2 \end{bmatrix} \quad \nabla^2 f = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 2x_3 & 2x_2 \\ 1 & 2x_2 & 0 \end{bmatrix} \text{ Hessian}$$

**Teorem:**  $\Omega \in \mathbb{R}^n$ ,  $f(\cdot) \in C^2$ ,  $x^* \in \Omega$

2. Mertebeden yeter koşul

$$(i) \nabla f(x^*) = 0$$

Nasıl hesaplanır?

(ii)  $H(x^*)$  kesin pozitif

$$\nabla^2 f = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 2x_3 & 2x_2 \\ 1 & 2x_2 & 0 \end{bmatrix} \quad \begin{matrix} x^T H x > 0 \\ \forall x \in \mathbb{R}^n \end{matrix}$$

$\rightarrow x^* \in \Omega$   $f(\cdot)$ 'in minimum noktasıdır.

### Doğrultu Belirleme (Line Search) Algoritması

- $x^{(0)}$  başlangıç noktasını belirle
- $s$  doğrultusunu belirle
- $f(x^{(k)} + \alpha s^{(k)})$ 'yi  $\alpha$ 'ya göre enazlayan  $\alpha^{(k)}$ 'yi belirle
- $x^{(k+1)} = x^{(k)} + \alpha^{(k)} s^{(k)}$  doğrultusunu belirle

Amaç:  $f(x^{(k+1)}) < f(x^{(k)})$

Beklenti: Algoritma fonksiyonu enazlayan  $x^*$ 'a yakınsayacak

Ne zaman sona erecek?  $|f(x^{(k+1)}) - f(x^{(k)})| < \varepsilon$

•  $s$  doğrultusunu belirle Nasıl ?

\*  $s^{(k)} \triangleq -\nabla f(x^{(k)}) \rightarrow$  "en dik iniş" (steepest descent)

\*  $\alpha^{(k)} s^{(k)} \triangleq -H^{-1}(x^{(k)}) \nabla f(x^{(k)}) \rightarrow$  Newton Metodu

\*  $\alpha^{(k)} s^{(k)} \triangleq -\frac{1}{2} [J^{(k)T} J^{(k)}]^{-1} \nabla f(x^{(k)}) \rightarrow$  Gauss-Newton Metodu

Bu doğrultuların işe yaradığını nasıl gösterebiliriz?

### Hatırlatma


$f(x)$ 'in  $x_0$  civarında Taylor serisi açılımı.

$$f(x) = f(x_0) + \frac{1}{1!} f'(x_0)(x - x_0) + \frac{1}{2!} f''(x_0)(x - x_0)^2 + \frac{1}{3!} f'''(x_0)(x - x_0)^3 + \dots$$

order

$$f(x) = e^{-x} \sin(x)$$

$$\hat{f}(x; 0) = x + \mathcal{O}(x^2)$$



### "En dik iniş " (steepest descent) Metodu

$s^{(k)} \triangleq -\nabla f(x^{(k)})$  ile  $f(x^{(k+1)}) < f(x^{(k)})$  sağlanır mı?

$f(x^{(k+1)})$  'yı hesaplamamanın bir yolu ne olabilir?

$f(x^{(k+1)})$  'yı  $x^{(k)}$  civarında Taylor serisine açalım.

$$f(x^{(k+1)}) \cong f(x^{(k)}) + \nabla f(x^{(k)})^T [x^{(k+1)} - x^{(k)}]$$

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} s^{(k)} \quad \leftarrow \quad s^{(k)} \triangleq -\nabla f(x^{(k)})$$

$$x^{(k+1)} - x^{(k)} = \alpha^{(k)} s^{(k)} \quad \rightarrow \quad x^{(k+1)} - x^{(k)} = -\alpha^{(k)} \nabla f(x^{(k)})$$

$$f(x^{(k+1)}) \cong f(x^{(k)}) - \alpha \nabla f(x^{(k)})^T \nabla f(x^{(k)})$$

$$f(x^{(k+1)}) \cong f(x^{(k)}) - \alpha \|\nabla f(x^{(k)})\|^2$$

$$\rightarrow f(x^{(k+1)}) < f(x^{(k)})$$

Sonuç:  $x^*$  'a yakınsayacak

Özel durum:  $f(x)$  **Kuadratik**  $\rightarrow f(x) = \frac{1}{2} x^T Q x - x^T b + c$

$\nabla f(x) = Qx - b$

Diagram:  $x^T b$  is a scalar product (vektör  $x$  and skaler  $b$ ).

1. Mertebeden gerek koşul  $\nabla f(x^*) = 0$

$$x^* = Q^{-1}b$$

$f(x)$  Kuadratik ise  $\rightarrow x^{(k+1)} - x^{(k)} = 0$

Uygun  $\alpha^{(k)}$  'yı belirlemenin bir yolu var mı?

•  $f(x^{(k)} + \alpha s^{(k)})$  'yı  $\alpha$  'ya göre enazlayan  $\alpha^{(k)}$  'yı belirle

$$\frac{d(f(x^{(k)} - \alpha^{(k)} \nabla f(x^{(k)})))}{d\alpha^{(k)}} = 0 \quad \rightarrow \quad \frac{d(f(x^{(k)} - \alpha^{(k)} (Qx^{(k)} - b)))}{d\alpha^{(k)}} = 0$$

$$\rightarrow \alpha^{(k)} = \frac{(Qx^{(k)} - b)^T (Qx^{(k)} - b)}{(Qx^{(k)} - b)^T Q (Qx^{(k)} - b)}$$

### Newton Metodu

$\alpha^{(k)} s^{(k)} \triangleq -H^{-1}(x^{(k)}) \nabla f(x^{(k)})$  ile  $f(x^{(k+1)}) < f(x^{(k)})$  sağlanır mı?

$f(x^{(k+1)})$ 'yı  $x^{(k)}$  civarında Taylor serisine açalım.

$$f(x^{(k+1)}) \cong f(x^{(k)}) + \nabla f(x^{(k)})^T [x^{(k+1)} - x^{(k)}] + \frac{1}{2} [x^{(k+1)} - x^{(k)}]^T H(x^{(k)}) [x^{(k+1)} - x^{(k)}]$$

$$x^{(k+1)} - x^{(k)} = \alpha^{(k)} s^{(k)} \quad \leftarrow \quad \alpha^{(k)} s^{(k)} \triangleq -H^{-1}(x^{(k)}) \nabla f(x^{(k)})$$

$$\begin{aligned} f(x^{(k+1)}) &\cong f(x^{(k)}) + \nabla f(x^{(k)})^T [-H^{-1}(x^{(k)}) \nabla f(x^{(k)})] \\ &\quad + \frac{1}{2} [-H^{-1}(x^{(k)}) \nabla f(x^{(k)})]^T H(x^{(k)}) [-H^{-1}(x^{(k)}) \nabla f(x^{(k)})] \\ f(x^{(k+1)}) &\cong f(x^{(k)}) - \nabla f(x^{(k)})^T H^{-1}(x^{(k)}) \nabla f(x^{(k)}) \\ &\quad + \frac{1}{2} [\nabla f(x^{(k)})^T H^{-1}(x^{(k)})^T \nabla f(x^{(k)})] \end{aligned}$$

$$f(x^{(k+1)}) \cong f(x^{(k)}) - \frac{1}{2} \nabla f(x^{(k)})^T H^{-1}(x^{(k)}) \nabla f(x^{(k)})$$

$$H(x^{(k)}) \text{ Kesin Pozitif ise} \quad \longrightarrow \quad f(x^{(k+1)}) < f(x^{(k)})$$

Sonuç:  $x^*$ 'a yakınsayacak

**EK BİLGİNİN SONU**

Amaç:  $\min_{w \in \mathbb{R}^{n+1}} E$  Neden vazgeçtik?

$$\begin{aligned} E &= \frac{1}{2} e^T e = (y_d - y)^T (y_d - y) = (y_d - \varphi(v))^T (y_d - \varphi(v)) \\ &= (y_d - \varphi(w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} 1))^T \\ &\quad (y_d - \varphi(w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} 1)) \end{aligned}$$

Böylece  $E$ 'nin  $w$ 'ya bağımlılığını açıkça yazdık, acaba  $\min_{w \in \mathbb{R}^{n+1}} E$  sağlayan  $w$ 'ları nasıl buluruz?

$E(w^{(k+1)}) \leq E(w^{(k)})$  sağlayacak  $w^{(k+1)}$ 'i  $w^{(k)}$ 'dan nasıl elde ederiz?

$$w^{(k)} + ? = w^{(k+1)} \quad \rightarrow \quad E(w^{(k+1)}) \leq E(w^{(k)})$$

$$w^{(k)} - c \nabla E = w^{(k+1)}$$

Nasıl bulunur?

$$E = \frac{1}{2} e^T e = \frac{1}{2} (y_d - y)^T (y_d - y) = \frac{1}{2} (y_d - \varphi(v))^T (y_d - \varphi(v))$$

$$v = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} x_{n+1}$$

$$\nabla E \triangleq \begin{bmatrix} \frac{\partial E}{\partial w_1} \\ \frac{\partial E}{\partial w_2} \\ \vdots \\ \frac{\partial E}{\partial w_{n+1}} \end{bmatrix} = \begin{bmatrix} \frac{\partial E}{\partial e} & \frac{\partial e}{\partial y} & \frac{\partial y}{\partial v} & \frac{\partial v}{\partial w} \end{bmatrix}$$

$\begin{matrix} \uparrow -1 \\ \downarrow e \end{matrix}$

$\begin{matrix} \uparrow \\ \downarrow \varphi'(v) \end{matrix}$

$\rightarrow$

$$\begin{bmatrix} \frac{\partial v}{\partial w_1} \\ \frac{\partial v}{\partial w_2} \\ \vdots \\ \frac{\partial v}{\partial w_{n+1}} \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ 1 \end{bmatrix}$$

$$\nabla E \triangleq \begin{bmatrix} \frac{\partial E}{\partial w_1} \\ \frac{\partial E}{\partial w_2} \\ \bullet \\ \bullet \\ \bullet \\ \frac{\partial E}{\partial w_{n+1}} \end{bmatrix} = \frac{\partial E}{\partial e} \frac{\partial e}{\partial y} \frac{\partial y}{\partial v} \frac{\partial v}{\partial w} = -(y_d - y)\phi'(v) \begin{bmatrix} x_1 \\ x_2 \\ \bullet \\ \bullet \\ \bullet \\ 1 \end{bmatrix}$$

Öğrenme Kuralı:

$$\Delta w = -(y_d - y)\phi'(v)x$$

Aktivasyon fonksiyonunu lineer alırsak ...

$$\Delta w = -(y_d - y)\phi'(v)x \rightarrow \Delta w = -(y_d - y)x$$

Bir de girişleri normalize edersek ...

$$\Delta w = -(y_d - y)\phi'(v)x \rightarrow \Delta w = -(y_d - y) \frac{x}{\|x\|}$$

ADALINE'ı nerede kullanabiliriz

- sınıflandırma probleminde

$$\text{Eğitim aşamasından sonra } y = \begin{cases} 1 & \sum_{i=1}^n w_{ij}x_i > 0 \\ -1 & \sum_{i=1}^n w_{ij}x_i \leq 0 \end{cases}$$

- Yaklaşık eğri uydurma (Lineer regresyon)



## Aktivasyon Fonksiyonun Seçimi

Eğitim değerler kümesi  $(-1,+1)$  aralığında ise

Aktivasyon fonksiyonu  $f(v) = \tanh(av)$  alınır.  
a parametresinin değer aralığı  $(0, 1)$

Eğitim değerler kümesi  $(0,+1)$  aralığında ise

Aktivasyon fonksiyonu  $f(v) = 1/(1+\exp(-av))$  alınır.  
a parametresinin değer aralığı  $(0, 1)$

Eğitim değerler kümesi  $(-5,+10)$  aralığında ise

Aktivasyon fonksiyonu  $f(v) = \tanh(av)$  alınır. Burada;

- Eğitim kümesi normalize edilebilir. Veya
- Aktivasyon fonksiyonu  $f(v) = 10*\tanh(av)$  olarak alınabilir.

## Aktivasyon Fonksiyonların 1. türevleri

### Hyperbolic Tangent Function

$$g(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$\begin{aligned} \frac{d}{dz} \left( \frac{e^z - e^{-z}}{e^z + e^{-z}} \right) &= \frac{e^z + e^{-z}}{(e^z + e^{-z})^2} d(e^z - e^{-z}) - \frac{e^z - e^{-z}}{(e^z + e^{-z})^2} d(e^z + e^{-z}) \\ &= \frac{(e^z + e^{-z})(e^z + e^{-z})}{(e^z + e^{-z})^2} - \frac{(e^z - e^{-z})(e^z - e^{-z})}{(e^z + e^{-z})^2} \\ &= \frac{(e^z + e^{-z})^2 - (e^z - e^{-z})^2}{(e^z + e^{-z})^2} \\ &= 1 - \frac{(e^z - e^{-z})^2}{(e^z + e^{-z})^2} \\ &= 1 - \tanh^2(z) \end{aligned}$$

### Sigmoid Function


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\frac{d(\sigma(x))}{dx} = \frac{0 * (1 + e^{-x}) - (1) * (e^{-x} * (-1))}{(1 + e^{-x})^2}$$

$$\frac{d(\sigma(x))}{dx} = \frac{(e^{-x})}{(1 + e^{-x})^2} = \frac{1 * 1 + (e^{-x})}{(1 + e^{-x})^2} = \frac{1 + e^{-x}}{(1 + e^{-x})^2} - \frac{1}{(1 + e^{-x})^2}$$

$$\frac{d(\sigma(x))}{dx} = \frac{1}{1 + e^{-x}} * \left( 1 - \frac{1}{1 + e^{-x}} \right) = \sigma(x)(1 - \sigma(x))$$

### Örnek 1 (Sınıflandırma)



İlk ağırlık  $w(1) = \begin{bmatrix} 0 \\ -1 \\ 0 \end{bmatrix}$

Öğrenme hızı  $c=0.7$

Durdurma ölçütü  $\varepsilon=0.01$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Eğitim kümesi:

$$\left( \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 3/2 \\ 3 \\ -1 \end{bmatrix} \right)$$

Test kümesi:

$$\left( \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} -3/2 \\ 3 \\ 1 \end{bmatrix} \right)$$



$$\left( \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 3/2 \\ 3 \\ -1 \end{bmatrix} \right)$$

#### 1. iterasyon

1. örüntü  $v_1 = w^T(1)x_1 \Rightarrow [0 \quad -1 \quad 0] \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix} = -2 \xrightarrow{\varphi} y_1 = -0.964$

$$w(2) = w(1) + c(y_{1d} - y_1)\varphi'(v_1)x_1$$

$$w(2) = \begin{bmatrix} 0 \\ -1 \\ 0 \end{bmatrix} + (0.7)(1 + 0.964)(0.0707) \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} -0.2914 \\ -0.8057 \\ 0.0971 \end{bmatrix}$$

$e = 1.9640$

2. örüntü  $v_2 = w^T(2)x_2 \Rightarrow w^T(2) \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} = -1.5828 \xrightarrow{\varphi} y_2 = -0.9190$

$$w(3) = w(2) + c(y_{2d} - y_2)\varphi'(v_2)x_2$$

$$w(3) = \begin{bmatrix} -0.2914 \\ -0.8057 \\ 0.0971 \end{bmatrix} + (0.7)(-1 + 0.9190)(0.1554) \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -0.3178 \\ -0.8145 \\ 0.0883 \end{bmatrix}$$

$e = -0.0810$



$$\left( \left\{ \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 3/2 \\ 3 \\ 1 \end{bmatrix} \right\} \right)$$

3. örüntü  $v_3 = w^T(3)x_3 \Rightarrow w^T(3) \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} = -0.4084 \xrightarrow{\varphi} y_3 = -0.3871$

$$w(4) = w(3) + c(y_{3d} - y_3)\varphi'(v_3)x_3$$

$$w(4) = \begin{bmatrix} -0.3178 \\ -0.8145 \\ 0.0883 \end{bmatrix} + (0.7)(\underbrace{1 + 0.3871}_{e=1.3871})(0.8501) \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1.1433 \\ 0.0109 \\ 0.9138 \end{bmatrix}$$

4. örüntü  $v_4 = w^T(4)x_4 \Rightarrow w^T(4) \begin{bmatrix} 3/2 \\ 3 \\ 1 \end{bmatrix} = -0.7683 \xrightarrow{\varphi} y_4 = -0.646$

$$w(5) = w(4) + c(y_{4d} - y_4)\varphi'(v_4)x_4$$

$$w(5) = \begin{bmatrix} -1.1433 \\ 0.0109 \\ 0.9138 \end{bmatrix} + (0.7)(\underbrace{-1 + 0.646}_{e=-0.354})(0.5827) \begin{bmatrix} 3/2 \\ 3 \\ 1 \end{bmatrix} = \begin{bmatrix} -1.3599 \\ -0.4223 \\ 0.7694 \end{bmatrix}$$

1. İterasyon sonunda durdurma ölçütünün sağlayıp sağlamadığı kontrol edilir.

4 örüntüye ilişkin hataların  $(y_d - y)$  kareleri alınır ve ortalaması hesaplanır.

$$e^T e = [1.9640 \quad -0.0810 \quad 1.3871 \quad -0.354] \begin{bmatrix} 1.964 \\ -0.081 \\ 1.3871 \\ -0.354 \end{bmatrix} = 5.9134$$

$$\text{Ortalama hata} = 5.9134 / 4 = 1.4783$$

Hata\_ortalama  $< \varepsilon = 0.01$  koşulunu sağlamadığı için ikinci iterasyona geçilir.

## 2. iterasyon

$$1. \text{ örneği } v_1 = w^T(5)x_1 \Rightarrow w^T(5) \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix} = 4.0045 \xrightarrow{\varphi} y_1 = 0.9993$$

$$w(6) = w(5) + c(y_{1d} - y_1)\varphi'(v_1)x_1$$

$$w(6) = \begin{bmatrix} -1.3599 \\ -0.4223 \\ 0.7694 \end{bmatrix} + (0.7)(1 - 0.9993)(0.0013) \begin{bmatrix} -3 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} -1.3599 \\ -0.4223 \\ 0.7694 \end{bmatrix}$$

$$2. \text{ örneği } w(7) = \begin{bmatrix} -1.3599 \\ -0.4223 \\ 0.7694 \end{bmatrix}$$

$$3. \text{ örneği } w(8) = \begin{bmatrix} -1.3654 \\ -0.4168 \\ 0.7749 \end{bmatrix}$$

$$4. \text{ örneği } w(9) = \begin{bmatrix} -1.3658 \\ -0.4175 \\ 0.7747 \end{bmatrix}$$



2. İterasyon sonunda durdurma ölçütünün sağlayıp sağlamadığı kontrol edilir.

4 örneğe ilişkin hataların  $(y_d - y)$  kareleri alınır ve ortalaması hesaplanır.

$$e^T e = [0.0007 \quad -0.0011 \quad 0.0637 \quad -0.0128] \begin{bmatrix} 0.0007 \\ -0.0011 \\ 0.0637 \\ -0.0128 \end{bmatrix} = 0.0042$$

$$\text{Ortalama hata} = 0.0042 / 4 = 0.00105$$

Hata\_ortalama  $< \varepsilon = 0.01$  koşulu sağladığından döngü sonlanır.



## Ağın testi

w(9) ağırlık değerleri kullanılarak test küme örüntülerinin sonuçları kontrol edilir.

Test kümesi:  $\left( \left\{ \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix}, -1 \right\}, \left\{ \begin{bmatrix} -3/2 \\ 3 \\ 1 \end{bmatrix}, 1 \right\} \right)$

1. Örüntü için ağ sonucu = -0.999998

1. Örüntü için olması gereken = -1



2. Örüntü için ağ sonucu = 0.917154

2. Örüntü için olması gereken = 1



### Hatırlatma

Eğitim aşamasından sonra 
$$y = \begin{cases} 1 & \sum_{i=1}^n w_{ij} x_i > 0 \\ -1 & \sum_{i=1}^n w_{ij} x_i \leq 0 \end{cases}$$



## Örnek (Yaklaşık eğri uydurma - Lineer regresyon)

$$f(x_1, x_2) = 3x_1 + 2\cos x_2, \quad x_1 \in [0,1], \quad x_2 \in [0, \pi/2]$$

İlk ağırlık  $w(0) = \begin{bmatrix} -0.1 \\ 0.1 \end{bmatrix}$  Öğrenme hızı  $c=0.7$   $\varepsilon=0.01$


```
x1=rand(1000,1);
x2=floor(rand(1000,1)*(pi/2));
x=[x1 x2];
yd=3*x1+2*cos(x2);
```

Ağın eğitimini 5 örüntü için hesaplayınız.

2'den fazla sınıfa ayırmak istersek, nasıl ayıracağız?

Unutulmaması gereken kısıt ne?

Verilenler:  $\{(x^l, y_d^l)\}_{l=1}^P$  Eğitim Kümesi



Amaç:  $y_d \in R^m$  iken bağıntıyı belirlemek

$$\begin{bmatrix} v_1^{(o)} \\ v_2^{(o)} \\ \vdots \\ v_m^{(o)} \end{bmatrix} = \begin{bmatrix} w_{11}^{(o)} & w_{12}^{(o)} & \dots & w_{1(n+1)}^{(o)} \\ w_{21}^{(o)} & w_{22}^{(o)} & \dots & w_{2(n+1)}^{(o)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{m1}^{(o)} & w_{m2}^{(o)} & \dots & w_{m(n+1)}^{(o)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix}$$

Hataya ilişkin fonksiyon aynı ancak bu sefer tek hata yok, her bir çıkış için hata var:

$$e = y_d - y \in R^m$$

$$E = \frac{1}{2} e^T e = (y_d - y)^T (y_d - y) = (y_d - \varphi(v))^T (y_d - \varphi(v))$$

$$= \begin{pmatrix} y_{d1} \\ y_{d2} \\ \vdots \\ y_{dm} \end{pmatrix} - \varphi \left( \begin{bmatrix} w_{11}^{(o)} & w_{12}^{(o)} & \dots & w_{1(n+1)}^{(o)} \\ w_{21}^{(o)} & w_{22}^{(o)} & \dots & w_{2(n+1)}^{(o)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{m1}^{(o)} & w_{m2}^{(o)} & \dots & w_{m(n+1)}^{(o)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} \right)^T$$

$$\begin{pmatrix} y_{d1} \\ y_{d2} \\ \vdots \\ y_{dm} \end{pmatrix} - \varphi \left( \begin{bmatrix} w_{11}^{(o)} & w_{12}^{(o)} & \dots & w_{1(n+1)}^{(o)} \\ w_{21}^{(o)} & w_{22}^{(o)} & \dots & w_{2(n+1)}^{(o)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{m1}^{(o)} & w_{m2}^{(o)} & \dots & w_{m(n+1)}^{(o)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} \right)$$

Öğrenme Kuralı:  $\Delta w = -((y_d - y) \times \varphi'(v)) x^T$  **ADALINE**

2'den fazla sınıfa ayırmak istersek, nasıl ayıracağız?


Amaç: m sınıfa ayırmak

$$S_1 : \sum_{i=1}^n w_i x_i + w_{n+1} < T_1$$

$$S_2 : T_1 \leq \sum_{i=1}^n w_i x_i + w_{n+1} < T_2$$

.....

$$S_m : T_{m-1} \leq \sum_{i=1}^n w_i x_i + w_{n+1} < T_m$$



Tek çıkışlıya göre farkı


Öğrenme Kuralı:  $\Delta w_{m \times (n+1)} = c \frac{1}{2} [y_d - y]_{m \times 1} (x^T)_{1 \times (n+1)}$

Perceptron (GAA)

$$\Delta w_{m \times (n+1)} = -((y_d - y)_{m \times 1} \times \phi'(v)_{m \times 1})(x^T)_{1 \times (n+1)}$$

ADALINE

Örneğin 4 sınıfa ayrılacak ise 4 nöronlu bir ağ oluşturulur.



Sınıflar için hedeflenen vektörler  
şöyle oluşturulur

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

Sınıf 1  
Sınıf 2  
Sınıf 3  
Sınıf 4



Vektörlerin  
birbirine  
olan hamming  
mesafesi aynı

✗  $\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

Vektörlerin birbirine  
olan hamming mesafesi farklı

## Hatırlatma

Her hangi 2 vektörün birbirine olan hamming mesafesi aynı

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \text{Hamming mesafesi 2}$$

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \Rightarrow \text{Hamming mesafesi 2}$$

$$\begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \Rightarrow \text{Hamming mesafesi 2}$$

## Öneriler

Bölüm 3 (Okunması önerilen)

-----  
S. Haykin, "Neural Networks and Learning Machines", 3<sup>rd</sup> Edition,  
Pearson International Edition, 2009, New Jersey.

İzlenmesi önerilenler

-----  
<https://www.youtube.com/watch?v=hc2Zj55j1zU>

<https://www.youtube.com/watch?v=skfNlwEbqck>